

# Curso Inteligência Artificial: do Zero ao Infinito

Redes Neurais Convolucionais

Universidade Federal de Mato Grosso

# Agenda

## 1 Introdução

## 2 Convolução

- Zero Padding
- Stride
- Dilatation
- Formula
- Pooling
- Kernel
- Channels
- Number of Filters

# Agenda

## 1 Introdução

## 2 Convolução

- Zero Padding
- Stride
- Dilatation
- Formula
- Pooling
- Kernel
- Channels
- Number of Filters

# Convolução

- **Convolução** é a simples aplicação de um filtro sobre uma entrada resultando em uma ativação.
- A aplicação de forma repetida de um filtro (ou kernel) sobre uma imagem resulta em um *mapa de ativação*, também chamado **mapa de features**.
- A principal vantagem é que os filtros preservam as relações espaciais entre os pixels.

# Convolução

- A inovação das **Redes Neurais Convolucionais** (CNNs) é a habilidade de automaticamente aprender um grande número de filtros.
- Camadas convolucionais podem conter diversos filtros, que são aplicados em paralelo.
- Como resultado, obtém-se diversos filtros especializados em extrair *features* específicas para determinadas tarefas.

Fonte: <https://machinelearningmastery.com/convolutional-layers-for-deep-learning-neural-networks/>

# Agenda

## 1 Introdução


## 2 Convolução

- Zero Padding
- Stride
- Dilatation
- Formula
- Pooling
- Kernel
- Channels
- Number of Filters

# Convolução



# Convolução



5	2	3	1	2	4
2	4	1	0	3	1
5	1	0	2	8	3
0	2	1	5	2	4
2	7	0	0	2	1
1	3	2	8	7	0



# Convolução

Image

5	2	3	1	2	4
2	4	1	0	3	1
5	1	0	2	8	3
0	2	1	5	2	4
2	7	0	0	2	1
1	3	2	8	7	0

Kernel

1	0	0
2	1	0
1	0	-1

# Convolução

Image

5	2	3	1	2	4
2	4	1	0	3	1
5	1	0	2	8	3
0	2	1	5	2	4
2	7	0	0	2	1
1	3	2	8	7	0

Kernel

1	0	0
2	1	0
1	0	-1

Output


# Convolução

Image

5	2	3	1	2	4
2	4	1	0	3	1
5	1	0	2	8	3
0	2	1	5	2	4
2	7	0	0	2	1
1	3	2	8	7	0

Kernel

1	0	0
2	1	0
1	0	-1

Output

	?				

# Convolução

Image

5	2	3	1	2	4
2	4	1	0	3	1
5	1	0	2	8	3
0	2	1	5	2	4
2	7	0	0	2	1
1	3	2	8	7	0

Kernel

1	0	0
2	1	0
1	0	-1

Output

	?				

$$\sum^P image_i \cdot K_i$$

# Convolução

Image

5	2	3	1	2	4
2	4	1	0	3	1
5	1	0	2	8	3
0	2	1	5	2	4
2	7	0	0	2	1
1	3	2	8	7	0

Kernel

1	0	0
2	1	0
1	0	-1

Output

	?				

$$\sum^P image_i \cdot K_i = 5 \cdot 1 + 2 \cdot 0 + \dots + 0 \cdot -1$$

# Convolução

Image

5	2	3	1	2	4
2	4	1	0	3	1
5	1	0	2	8	3
0	2	1	5	2	4
2	7	0	0	2	1
1	3	2	8	7	0

Kernel

1	0	0
2	1	0
1	0	-1

Output

	?				

$$\sum^P image_i \cdot K_i = 5 \cdot 1 + 2 \cdot 0 + \dots + 0 \cdot -1 = 18$$

# Convolução

Image

5	2	3	1	2	4
2	4	1	0	3	1
5	1	0	2	8	3
0	2	1	5	2	4
2	7	0	0	2	1
1	3	2	8	7	0

Kernel

1	0	0
2	1	0
1	0	-1

Output

	18				

$$\sum^P image_i \cdot K_i = 5 \cdot 1 + 2 \cdot 0 + \dots + 0 \cdot -1 = 18$$

# Convolução

Image						Kernel			Output					
5	2	3	1	2	4	1	0	0						
2	4	1	0	3	1	2	1	0	18	10				
5	1	0	2	8	3	1	0	-1						
0	2	1	5	2	4									
2	7	0	0	2	1									
1	3	2	8	7	0									

$$\sum^P image_i \cdot K_i = 5 \cdot 1 + 2 \cdot 0 + \dots + 0 \cdot -1 = 18$$



# Revisão

## Convolução

Image						Kernel			Output					
5	2	3	1	2	4	1	0	0						
2	4	1	0	3	1	2	1	0	18	10	-3			
5	1	0	2	8	3	1	0	-1						
0	2	1	5	2	4									
2	7	0	0	2	1									
1	3	2	8	7	0									

$$\sum^P image_i \cdot K_i = 5 \cdot 1 + 2 \cdot 0 + \dots + 0 \cdot -1 = 18$$

# Convolução

Image						Kernel			Output					
5	2	3	1	2	4	1	0	0						
2	4	1	0	3	1	2	1	0	18	10	-3	5		
5	1	0	2	8	3	1	0	-1						
0	2	1	5	2	4									
2	7	0	0	2	1									
1	3	2	8	7	0									

$$\sum^P image_i \cdot K_i = 5 \cdot 1 + 2 \cdot 0 + \dots + 0 \cdot -1 = 18$$

# Convolução

Image

5	2	3	1	2	4
2	4	1	0	3	1
5	1	0	2	8	3
0	2	1	5	2	4
2	7	0	0	2	1
1	3	2	8	7	0

Kernel

1	0	0
2	1	0
1	0	-1

Output

	18	10	-3	5	
	12				

$$\sum^P image_i \cdot K_i = 5 \cdot 1 + 2 \cdot 0 + \dots + 0 \cdot -1 = 18$$

# Convolução

Image

5	2	3	1	2	4
2	4	1	0	3	1
5	1	0	2	8	3
0	2	1	5	2	4
2	7	0	0	2	1
1	3	2	8	7	0

Kernel

1	0	0
2	1	0
1	0	-1

Output

	18	10	-3	5	
	12	?	?	?	
	?	?	?	?	
	?	?	?	?	

$$\sum^P image_i \cdot K_i = 5 \cdot 1 + 2 \cdot 0 + \dots + 0 \cdot -1 = 18$$

# Convolução

Image

	5	2	3	1	2	4
	2	4	1	0	3	1
	5	1	0	2	8	3
	0	2	1	5	2	4
	2	7	0	0	2	1
	1	3	2	8	7	0

Kernel

1	0	0
2	1	0
1	0	-1

Output

	18	10	-3	5	
	12	?	?	?	
	?	?	?	?	
	?	?	?	?	

# Convolução

## Zero Padding

- A operação de convolução pode impactar na dimensão da imagem resultado, reduzindo-a consideravelmente
- **Padding** é o processo em que alguns pixels são adicionados ao redor da imagem
- Assim é possível manter a dimensionalidade na imagem resultante após uma operação de convolução

Fonte: [Uma introdução as redes neurais convolucionais utilizando o Keras](#)

# Convolução

## Zero Padding

Image							
0	0	0	0	0	0	0	0
0	5	2	3	1	2	4	0
0	2	4	1	0	3	1	0
0	5	1	0	2	8	3	0
0	0	2	1	5	2	4	0
0	2	7	0	0	2	1	0
0	1	3	2	8	7	0	0
0	0	0	0	0	0	0	0

Kernel		
1	0	0
2	1	0
1	0	-1

Output					
-1					
	18	10	-3	5	
	12	?	?	?	
	?	?	?	?	
	?	?	?	?	

# Convolução


Image							
0	0	0	0	0	0	0	0
0	5	2	3	1	2	4	0
0	2	4	1	0	3	1	0
0	5	1	0	2	8	3	0
0	0	2	1	5	2	4	0
0	2	7	0	0	2	1	0
0	1	3	2	8	7	0	0
0	0	0	0	0	0	0	0

Kernel		
1	0	0
2	1	0
1	0	-1

Output					
-1	?	?	?	?	?
?	18	10	-3	5	?
?	12	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?
?	?	?	?	?	?



# Convolução



# Convolução

## Stride

- Algumas vezes é necessário “compactar” alguns pixels da imagem
- **Stride** indica o tamanho do deslocamento ao deslizar o *kernel* sobre a imagem
- Indicado em pixels

# Convolução

## Stride

Quando stride é 1, descola-se 1 pixel por vez

5	2	3	1	2	4
2	4	1	0	3	1
5	1	0	2	8	3
0	2	1	5	2	4
2	7	0	0	2	1
1	3	2	8	7	0

# Convolução

## Stride

Quando stride é 1, descola-se 1 pixel por vez

5	2	3	1	2	4
2	4	1	0	3	1
5	1	0	2	8	3
0	2	1	5	2	4
2	7	0	0	2	1
1	3	2	8	7	0

# Convolução

## Stride

Quando stride é 1, descola-se 1 pixel por vez

5	2	3	1	2	4
2	4	1	0	3	1
5	1	0	2	8	3
0	2	1	5	2	4
2	7	0	0	2	1
1	3	2	8	7	0

# Convolução

## Stride

Quando stride é 2, descola-se 2 pixels por vez

5	2	3	1	2	4
2	4	1	0	3	1
5	1	0	2	8	3
0	2	1	5	2	4
2	7	0	0	2	1
1	3	2	8	7	0

# Convolução

## Stride

Quando stride é 2, descola-se 2 pixels por vez

5	2	3	1	2	4
2	4	1	0	3	1
5	1	0	2	8	3
0	2	1	5	2	4
2	7	0	0	2	1
1	3	2	8	7	0

# Convolução

## Dilatação


- Algumas vezes é interessante “pular” alguns valores. Ex. ao se trabalhar com imagens de grande dimensão
- **Convoluções Dilatadas** permitem que o *kernel* aumente o “alcance de visão”, sem aumentar o número de parâmetros
- Também há perda de informação, pois nem todos os pixels são processados

Fonte: [Types of Convolution Kernels : Simplified](#)



# Convolução

## Dilatação



Fonte: [Multiscale Spatial-Spectral Convolutional Network with Image-Based Framework for Hyperspectral Imagery Classification](#)

# Formula

A fórmula da convolução

$$Out = \frac{(In - F + 2P)}{S} + 1$$

em que

- $In$  é o tamanho da entrada
- $F$  é o tamanho do campo receptivo (kernel)
- $P$  é a quantidade de *zero padding* na borda
- $S$  é o *stride*

Referência: [Convolutional Neural Networks for Visual Recognition](#)

# Pooling

- Outra estratégia para reduzir a dimensionalidade de uma imagem de entrada é utilizar camadas de **pooling**
- São também chamadas de camadas *downsampling* or *subsampling*
- Existem três diferentes tipos de *pooling* espacial:
  - ▶ Max Pooling
  - ▶ Average Pooling
  - ▶ Sum Pooling

Referência: [Types of Convolution Kernels : Simplified](#)

# Max Pooling

Max Pooling: 2x2 stride 2

Input

-1	2	0	2
3	18	10	-3
2	12	5	2
1	3	7	4

Output


# Max Pooling

Max Pooling: 2x2 stride 2

Input

-1	2	0	2
3	18	10	-3
2	12	5	2
1	3	7	4

Output

18	

# Max Pooling

Max Pooling: 2x2 stride 2

Input

-1	2	0	2
3	18	10	-3
2	12	5	2
1	3	7	4

Output

18	10

# Max Pooling

Max Pooling: 2x2 stride 2

Input

-1	2	0	2
3	18	10	-3
2	12	5	2
1	3	7	4

Output

10	18
12	

# Max Pooling

Max Pooling: 2x2 stride 2

Input

-1	2	0	2
3	18	10	-3
2	12	5	2
1	3	7	4

Output

10	18
12	7



# Kernel

- Detectores de *Features*.
- *Kernels* são definidos durante o processo de treinamento.

# Kernel

## Blur

1/9	1/9	1/9
1/9	1/9	1/9
1/9	1/9	1/9



A simple blur done with convolutions

# Kernel

## Gaussian Blur

0	0	0	5	0	0	0
0	5	18	32	18	5	0
0	18	64	100	64	18	0
5	32	100	100	100	32	5
0	18	64	100	64	18	0
0	5	18	32	18	5	0
0	0	0	5	0	0	0



Fonte: Image convolution examples

# Kernel

## Line Detection

-1	-1	-1
2	2	2
-1	-1	-1

Horizontal lines

-1	2	-1
-1	2	-1
-1	2	-1

Vertical lines

-1	-1	2
-1	2	-1
2	-1	-1

45 degree lines

2	-1	-1
-1	2	-1
-1	-1	2

135 degree lines



# Kernel

## *Edge Detection*

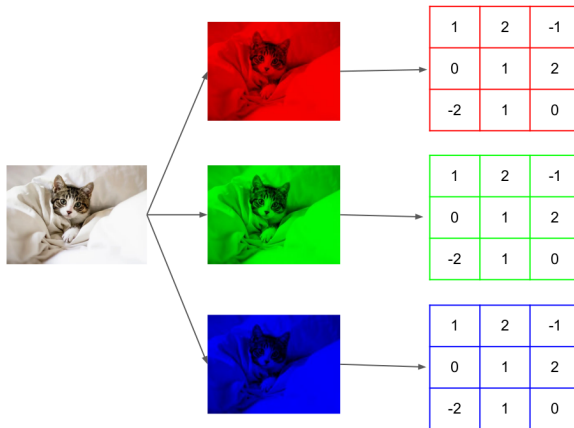
-1	-1	-1
-1	8	-1
-1	-1	-1



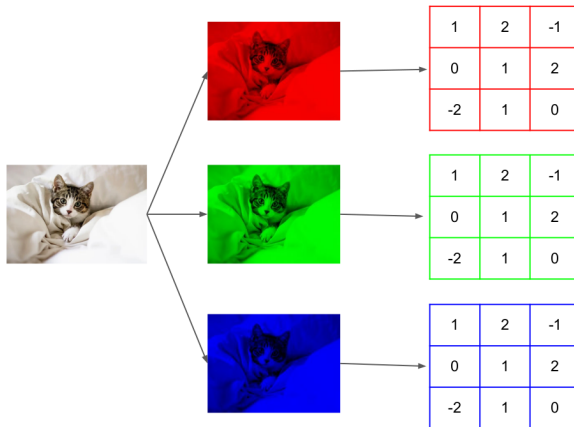
# CNN Architecture

- Imagens coloridas possuem três canais: Red x Green x Blue

# Channels



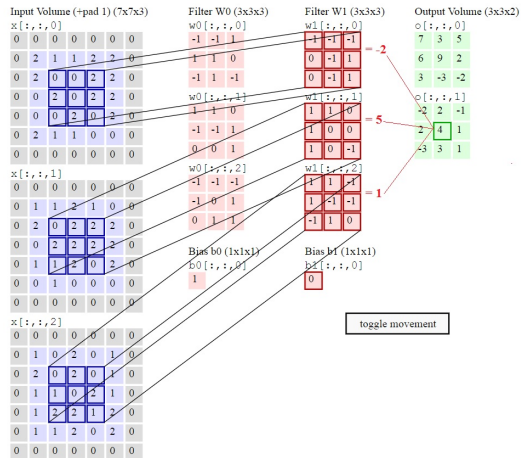
# Channels



kernel = 3 x 3 x 3, N<sup>o</sup> Pesos = 27




# Number of Filters



Fonte: Convolutional Neural Networks (CNNs / ConvNets)

# Number of Filters



Total de Pesos:  $3 \times 3 \times 3 * 2 + 2 = 56$

Fonte: Implementing 'SAME' and 'VALID' padding of Tensorflow in Python

# Referências

- Intuitively Understanding Convolutions for Deep Learning
  - ▶ <https://towardsdatascience.com/intuitively-understanding-convolutions-for-deep-learning-1f6f42faee1>
- Convolutional Neural Networks, Explained
  - ▶ <https://towardsdatascience.com/convolutional-neural-networks-explained-9cc5188c4939>
- Image convolution examples
  - ▶ <https://aishack.in/tutorials/image-convolution-examples/>
- Types of Convolution Kernels : Simplified
  - ▶ <https://towardsdatascience.com/types-of-convolution-kernels-simplified-f040cb307c37>

# Curso Inteligência Artificial: do Zero ao Infinito

Redes Neurais Convolucionais

Universidade Federal de Mato Grosso